



西安培華學院

《Python 与人工智能》项目报告

(2025-2026 学年 第 2 学期)

项目名称: 基于高阶累积量和随机森林算法对调制信号的自动识别

学 号: 20232B1123

姓 名: 曾俊超

班 级: 2023 电子信息工程 02

学 院: 智能科学与工程学院

2026 年 6 月

一、项目背景与目的

本项目基于高阶累积量（Higher-Order Cumulants, HOC）和随机森林（Random Forest）算法，实现了对 BPSK、QPSK、8PSK、16QAM 四种常见数字调制信号的自动识别（Automatic Modulation Recognition, AMR）。

在认知无线电、频谱监测、电子战和非合作通信等领域，调制识别是信号解调的前置关键步骤。传统方法依赖专家经验和固定阈值判断，难以适应复杂多变的电磁环境。高阶累积量是通信信号处理中的重要数学工具，其核心优势在于：对于高斯白噪声，所有高于二阶的累积量恒为零，因此高阶累积量天然具有抑制高斯噪声的能力。结合随机森林集成学习算法的鲁棒性和可解释性，可以构建一个高性能的端到端调制识别系统。

项目要解决的具体问题是：如何从接收到的调制信号中自动提取高阶累积量特征（C20、C21、C40、C41、C42、C60、C63 共 7 维），利用随机森林分类器准确识别信号的调制类型，并通过超参数调优、交叉验证、SNR 扫描实验等手段全面评估系统性能。

二、数据来源与数据集介绍

数据采用蒙特卡洛模拟生成，参考通信信号处理经典文献（Swami & Sadler, 2000）中高阶累积量的理论值，并加入高斯噪声模拟实际信道对累积量估计的影响。共生成 2000 个样本，每类调制信号 500 个。每个样本包含 7 个高阶累积量特征和 1 个调制类型标签。

高阶累积量的定义如下：对于零均值复信号 s （归一化功率 $E[|s|^2]=1$ ），二阶累积量 $C20=E[s^2]$ 反映信号的循环对称性， $C21=E[|s|^2]=1$ 反映信号功率；四阶累积量 $C40$ 、 $C41$ 、 $C42$ 反映信号的超高斯特性，与星座图几何结构直接相关；六阶累积量 $C60$ 、 $C63$ 在理想归一化条件下为零。

各特征说明及理论值如下表所示：

特征	类型	含义	BPSK	QPSK	8PSK	16QAM
C20	浮点	二阶混合矩	1.00	0.00	0.00	0.00

C21	浮点	二阶共轭矩	1.00	1.00	1.00	1.00
C40	浮点	四阶累积量	-2.00	-1.00	0.00	-0.68
C41	浮点	四阶累积量	-2.00	-1.00	0.00	-0.68
C42	浮点	四阶累积量	-2.00	-1.00	-1.00	-0.68
C60	浮点	六阶累积量	0.00	0.00	0.00	0.00
C63	浮点	六阶累积量	0.00	0.00	0.00	0.00
标签	整型	调制类型	0	1	2	3

表 1 高阶累积量特征说明及四种调制信号的理论值

从表 1 可以看出：C20 可以唯一区分 BPSK（非零）与其他三种循环对称调制（为零）；四阶累积量 C40、C41、C42 是区分 QPSK、8PSK、16QAM 的关键特征，其中 QPSK 与 16QAM 的比值为-1.00/-0.68≈1.47（47%差异），这是两者易混淆的数学根源；C60 和 C63 在理想条件下均为零，区分能力有限。

三、数据预处理

数据预处理包括以下步骤：

1. 缺失值处理：经检查，模拟生成的数据无缺失值，无需额外处理。
2. 异常值检测：通过概率密度分布图（图 1）未发现明显异常值，各特征分布符合预期的正态分布特性。
3. 数据标准化：使用 StandardScaler 将每个特征缩放为均值为 0、方差为 1 的标准正态分布。虽然随机森林对特征尺度不敏感，但标准化有助于后续可视化展示和与 KNN 等距离敏感算法的公平对比。
4. 数据集划分：按 7:3 比例划分训练集（1400 个）和测试集（600 个），采用分层抽样（stratify）保证各类别在训练集和测试集中的比例一致。

关键代码如下：

```
# 数据标准化
from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_raw)
```

```
# 数据集划分（7:3，分层抽样）
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.3, random_state=42, stratify=y
)
```




图 1 各高阶累积量特征的概率密度分布（按调制类型着色）

四、候选模型对比与选择

在确定最终分类器之前，本项目对五种主流机器学习模型进行了系统评估，从算法原理、对高阶累积量特征的适应性、抗噪声能力、是否支持特征重要性输出、可解释性以及训练速度等维度进行对比。

(1) 候选模型概述

- ① K 近邻（KNN）：基于距离度量的惰性学习算法，通过计算测试样本与训练样本的距离，取最近 k 个邻居的多数投票作为预测结果。无需显式训练过程，但预测时需要遍历全部训练数据。
- ② 支持向量机（SVM）：通过在高维空间中寻找最大间隔超平面来分隔不同类别。使用核技巧（如 RBF 核）可处理非线性问题，在小样本场景下表现优异。
- ③ 决策树（DT）：通过递归地选择最优特征进行分裂，构建树状决策规则。训练速度快，可解释性强，但单棵树容易过拟合，对噪声敏感。

④ 逻辑回归（LR）：线性分类器，通过 sigmoid/softmax 函数将线性组合映射为类别概率。模型简单，训练速度快，但假设线性可分，对复杂非线性边界建模能力有限。

⑤ 随机森林（RF）：集成学习方法，通过自助采样（Bagging）构建多棵决策树并投票。兼具决策树的可解释性和集成方法的鲁棒性。

（2）多维度对比分析

表 2 从六个关键维度对五种候选模型进行了系统对比。

对比维度	KNN	SVM (RBF)	决策树	逻辑回归	随机森林
算法原理	距离度量 +多数投票	最大间隔 超平面	递归特征 分裂	线性组合 +Softmax	Bagging +决策树投票
对 7 维 HOC 特征适应性	中等 (距离度量受 特征尺度影响)	优秀 (核函数映射 高维空间)	良好 (自动选择 分裂特征)	较差 (假设线性 可分)	优秀 (随机子空间 +自动选择)
抗噪声能力	较差 (噪声样本 直接影响 距离计算)	良好 (仅支持向量 决定边界)	较差 (单棵树易 拟合噪声)	中等 (线性边界 受噪声偏移)	优秀 (集成投票 抑制噪声)
特征重要性 输出	不支持	不支持 (仅支持向量 可间接分析)	支持 (基于不纯度 减少量)	支持 (系数权重)	支持 (MDI/置换 重要性)
可解释性	中等 (可查看近邻 但高维困难)	较差 (核空间 不可见)	优秀 (决策规则 可直接阅读)	优秀 (系数直接 可解释)	良好 (特征重要性 +单棵树可 查)
训练速度	无需训练 (预测慢)	较慢 ($O(n^2 \sim n^3)$)	极快	极快	中等 (B 棵树 并行训练)

表 2 五种候选机器学习模型多维度对比

（3）基于项目需求的模型选择

本项目具有以下关键特征和需求：

① 小样本场景：总计 2000 个训练样本，每类 500 个，属于中小规模数据集。
SVM 在小样本下表现优异，但不支持特征重要性输出；KNN 在高维小样本下受维度灾难影响。

② 中等维度特征：7 维高阶累积量特征，维度不高但特征间存在理论关联（如 C40 与 C41 来自同阶累积量）。需要模型能自动捕捉特征间的交互作用。

③ 可解释性需求：作为通信信号处理项目，需要理解哪些累积量特征对识别贡献最大，以验证通信理论。随机森林和决策树的特征重要性输出可直接满足此需求，而 SVM 和 KNN 无法提供。

④ 抗噪声鲁棒性：实际通信环境中存在信道噪声、多径干扰等非理想因素。随机森林通过集成投票有效抑制单棵树对噪声的过拟合，而单棵决策树和 KNN 的抗噪能力较弱。

⑤ 特征重要性输出：需要量化各高阶累积量的贡献，以验证“四阶累积量主导区分”的理论预测。仅决策树、逻辑回归和随机森林支持此功能，但逻辑回归的线性假设限制了其对非线性特征交互的建模能力。

综合以上分析，随机森林在抗噪声能力、特征重要性输出、可解释性和对中等维度特征的适应性方面均表现优异，且训练速度可接受（200 棵树在 2000 样本上训练时间 < 1 秒）。因此，本项目最终选择随机森林作为核心分类器，并以决策树和 KNN 作为基线对比算法。

五、模型构建与分析

（1）算法原理

随机森林（Random Forest）由 Breiman（2001）提出，是一种基于 Bagging 的集成学习方法。其核心思想是通过引入两层随机性来增加模型多样性：第一层是对训练集进行自助采样（Bootstrap），每棵树使用不同的训练子集；第二层是在每个节点分裂时，从 p 个特征中随机选择 m 个（通常 $m \approx \sqrt{p}$ ）作为候选分裂特征，选择最优分裂点。

对于分类任务，最终预测采用多数投票法： $\hat{y} = \operatorname{argmax}_c \sum_{b=1}^B I(T_b(x) = c)$ ，其中 B 为树的数量， T_b 为第 b 棵树的预测。这种集成机制有效降低了单棵决策树的高方差问题，在偏差基本不变的前提下显著减小泛化误差。

（2）超参数设置

使用网格搜索（GridSearchCV）结合 5 折分层交叉验证，在以下超参数空间中搜索最优组合：

（2）算法原理

随机森林在训练阶段对原始数据进行 B 次自助采样（Bootstrap），分别训练 B 棵决策树。每棵树在每个节点分裂时，随机选择 $m \approx \sqrt{p}$ 个特征（ p 为特征维度）作为候选，选择最优分裂。预测阶段对分类任务采用多数投票法： $\hat{y} = \operatorname{argmax}_c \sum I(T_b(x)=c)$ 。

（3）超参数调优

使用网格搜索（GridSearchCV）结合 5 折分层交叉验证，在以下超参数空间中搜索最优组合：

超参数	搜索范围	含义
n_estimators	{50, 100, 200}	决策树数量
max_depth	{5, 10, 20, None}	树的最大深度
min_samples_split	{2, 5, 10}	节点最小分裂样本数

表 3 超参数搜索空间

搜索空间共 $3 \times 4 \times 3 = 36$ 种组合，每种组合进行 5 折交叉验证，共执行 180 次模型训练。

关键代码如下：

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import GridSearchCV, StratifiedKFold

param_grid = {
    'n_estimators': [50, 100, 200],
    'max_depth': [5, 10, 20, None],
    'min_samples_split': [2, 5, 10]
}
rf = RandomForestClassifier(random_state=42, n_jobs=-1)
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
grid_search = GridSearchCV(rf, param_grid, cv=cv,
                           scoring='accuracy', n_jobs=-1)
grid_search.fit(X_train, y_train)
best_rf = grid_search.best_estimator_
```

（4）调优结果

网格搜索确定的最优超参数组合为：n_estimators=200、max_depth=10、min_samples_split=10。5 折交叉验证最佳准确率为 86.50%±1.73%。最终测试集准确率为 90.83%。

排名	n_estimators	max_depth	min_samples_split	CV 准确率
1	200	10	10	86.50% ± 1.73%
2	50	10	10	86.36% ± 2.01%
3	100	10	10	86.21% ± 1.71%
4	100	20	10	86.14% ± 1.47%
5	200	None	5	86.14% ± 1.74%

表 4 GridSearchCV Top-5 超参数组合

六、结果分析与可视化

1. 混淆矩阵分析

图 2 展示了随机森林在测试集（600 个样本）上的混淆矩阵。对角线元素表示正确分类的样本数，非对角线元素表示误分类。




图 2 随机森林混淆矩阵（测试集，N=600）

分析：BPSK 识别准确率最高（100%），因其 C20=1.00 可被唯一区分；8PSK 次之（98.0%），因 C40=C41=0.00 与其他调制差异明显；主要误分类来源是 QPSK 与 16QAM 之间的混淆——QPSK 有 12.7%被误判为 16QAM，16QAM 有 19.3%被误判为 QPSK。这与理论分析一致：两者共享 C20=0、C21=1，仅靠 C40/C41/C42 的 47%差异区分，在噪声下分布重叠。

分类详细报告如下：

类别	精确率	召回率	F1 分数	支持数
----	-----	-----	-------	-----

BPSK	1.0000	1.0000	1.0000	150
QPSK	0.8344	0.8733	0.8534	150
8PSK	0.9423	0.9800	0.9608	150
16QAM	0.8540	0.7800	0.8153	150
宏平均	0.9077	0.9083	0.9074	600

表 5 随机森林分类报告（测试集）

2. 特征重要性分析

图 3 展示了随机森林基于基尼不纯度减少量（MDI）输出的特征重要性排序。




图 3 特征重要性排序（随机森林，MDI 准则）

排名	特征	重要性分数	累积占比
#1	C41	0.3063	30.6%
#2	C40	0.2902	59.7%
#3	C20	0.1952	79.2%
#4	C42	0.1418	93.4%
#5	C60	0.0233	95.7%
#6	C21	0.0229	98.0%
#7	C63	0.0203	100.0%

表 6 特征重要性排名

四阶累积量 C41（30.6%）和 C40（29.0%）贡献最大，合计占比近 60%；C20（19.5%）排名第三，主要负责区分 BPSK；C42（14.2%）排名第四。前四个特征合计贡献 93.4% 的分类信息。六阶累积量 C60、C63 和二阶共轭矩 C21 的贡献均低

于 2.5%，与理论预期一致——C60、C63 在理想条件下为零，C21 对四种调制均为 1.00。该结果从数据层面验证了四阶累积量在调制识别中的主导作用。

3. ROC 曲线与 AUC 值

图 4 展示了多分类 ROC 曲线（One-vs-Rest 策略）。AUC 值衡量分类器在所有阈值下的综合判别能力。




图 4 多分类 ROC 曲线（One-vs-Rest）

类别	AUC 值
BPSK	1.0000
QPSK	0.9682
8PSK	0.9977
16QAM	0.9578
微平均	0.9880

表 7 各类别 AUC 值

所有类别的 AUC 值均超过 0.95，微平均 AUC 达到 0.9880，表明模型具有极佳的分类区分能力。BPSK 的 AUC 为 1.0000（完美），与混淆矩阵中零误分类一致。16QAM 的 AUC 最低（0.9578），是 QPSK-16QAM 混淆的反映。

4. 学习曲线分析

图 5 展示了学习曲线，用于诊断模型是否存在过拟合或欠拟合。




图 5 学习曲线（偏差-方差诊断）

训练集准确率在样本量较小时为 1.00（完全拟合），随样本量增加略有下降至 94.9%，这是随机森林对训练数据拟合能力的正常反映。交叉验证准确率从 25.0%（样本极少时的随机猜测）单调上升至 87.1%，呈现良好的收敛趋势。训练-CV 差距从 0.75 逐步缩小至 0.078，表明：（1）模型不存在严重过拟合——若过拟合，训练准确率应始终接近 1.00 而 CV 准确率停滞；（2）当前数据量（2000 样本）对 7 维特征已基本充足，继续增加数据的边际收益递减。

5. 信噪比（SNR）扫描实验

为评估系统在不同信道条件下的鲁棒性，进行 SNR 扫描实验：对每个 SNR 值重新生成数据集，使用相同的最优超参数训练随机森林并测试。




图 6 分类准确率随 SNR 变化曲线

SNR (dB)	准确率
0	89.00%
5	96.00%
10	99.83%
15	100.00%
20	100.00%
25	100.00%
30	100.00%

表 8 SNR vs 分类准确率

曲线呈现典型的 S 形特征：SNR=0dB 时准确率仍有 89%（得益于高阶累积量的噪声抑制能力），SNR 在 5-10dB 区间快速提升，SNR≥15dB 后达到 100%。拐点出现在 10dB 附近，这为实际系统设计提供了明确的性能指标：当接收信噪比超过 10dB 时，系统可实现完美识别。值得注意的是，即使在极低 SNR=0dB 下，准确率仍远高于随机猜测（25%），体现了高阶累积量特征的内在鲁棒性。

6. 基线算法对比

为验证随机森林的优越性，在相同数据集和预处理条件下，与决策树和 KNN（k=5）进行对比。




图 7 三种算法测试集准确率对比

算法	准确率	训练时间(s)	测试时间(s)
决策树	82.67%	0.0132	0.0000
KNN (k=5)	83.17%	0.0051	0.0250
随机森林	90.83%	0.0000*	0.0770

表 9 三种算法性能对比

*随机森林因已被 GridSearchCV 训练完成，此处仅计测试时间。

算法	BPSK	QPSK	8PSK	16QAM	宏平均 F1
决策树	0.993	0.726	0.926	0.660	0.826
KNN (k=5)	1.000	0.754	0.925	0.635	0.828
随机森林	1.000	0.853	0.961	0.815	0.907

表 10 各算法各类别 F1 分数对比

随机森林在整体准确率（90.83%）和宏平均 F1（0.907）上均显著优于决策树（82.67%，0.826）和 KNN（83.17%，0.828），提升幅度达 7-8 个百分点。分类别看，随机森林在最具挑战性的 QPSK 和 16QAM 上优势最明显：QPSK 的 F1 从 0.726/0.754 提升至 0.853，16QAM 从 0.660/0.635 提升至 0.815。这体现了集成学习通过聚合多棵树的预测来降低方差、提升泛化能力的核心优势。

7. 模拟星座图

作为辅助可视化，图 8 展示了四种调制信号在 IQ 平面上的模拟星座图，直观体现不同调制的信号空间分布差异。

Fig. 2. Simulated Constellation Diagrams with AWGN




图 8 四种调制信号的模拟星座图（SNR≈20dB）

七、总结与收获

（1）项目成果

成功构建了一个基于高阶累积量和随机森林的调制识别系统，测试集准确率达 90.83%，微平均 AUC 达 0.9880，能够可靠区分 BPSK、QPSK、8PSK、16QAM 四种调制信号。系统在 $\text{SNR} \geq 10\text{dB}$ 时即可实现接近完美的识别性能。

（2）核心发现

① 四阶累积量（C40、C41、C42）是调制识别的主导特征，合计贡献 93.4% 的分类信息，从实验角度验证了通信信号处理理论。

② QPSK 与 16QAM 的混淆是系统主要误差来源，数学根源在于两者共享 $C_{20}=0$ 、 $C_{21}=1$ ，仅靠 $C_{40}/C_{41}/C_{42}$ 的 47% 差异区分。

③ 随机森林 (90.83%) 显著优于单棵决策树 (82.67%) 和 KNN (83.17%)，验证了集成学习的优势。

(3) 实践收获

① 掌握了完整的机器学习项目流程：数据生成→预处理→特征工程→模型选择→超参数调优→交叉验证→评估可视化。

② 深入理解了 GridSearchCV 的工作机制：5 折交叉验证如何平衡偏差与方差，超参数搜索空间的设计原则。

③ 学会了用混淆矩阵、ROC 曲线、学习曲线、SNR 扫描等多种手段全面评估分类器性能。

(4) 遇到的困难与解决

① QPSK 与 16QAM 的高混淆率问题：通过特征重要性分析定位到四阶累积量是关键区分特征，但两者理论值仅差 47%，在噪声下重叠严重。解决方案可包括增加观测窗口长度降低累积量估计方差，或引入瞬时频率/幅度统计量等辅助特征。

② 中文显示问题：在不同运行环境（本地 Windows vs Google Colab）中，matplotlib 的中文字体支持不同，通过条件检测和字体回退机制解决。

(5) 改进方向

① 未来可采集真实软件无线电平台（如 HackRF、USRP）的信号数据，验证实际环境下的性能。

② 可尝试深度学习方法（如一维 CNN、LSTM）实现端到端的特征提取和分类，可能进一步提升 QPSK-16QAM 的区分能力。

③ 增加更多调制类型（如 OFDM、GMSK、APSK）以扩展系统适用范围。

参考文献

- [1] O. A. Dobre, A. Abdi, Y. Bar-Ness, and W. Su, "Survey of automatic modulation classification techniques: Classical approaches and new trends," IET Communications, vol. 1, no. 2, pp. 137-156, 2007.
- [2] W. Wei and J. M. Mendel, "Maximum-likelihood classification for digital amplitude-phase modulations," IEEE Trans. Commun., vol. 48, no. 2, pp. 189-193, Feb. 2000.
- [3] A. Swami and B. M. Sadler, "Hierarchical digital modulation classification using cumulants," IEEE Trans. Commun., vol. 48, no. 3, pp. 416-429, Mar. 2000.
- [4] C. M. Spooner, "On the utility of sixth-order cumulants for distinguishing communication signals," IEEE Trans. Signal Process., vol. 46, no. 6, pp. 1739-1743, Jun. 1998.
- [5] L. Breiman, "Random forests," Machine Learning, vol. 45, no. 1, pp. 5-32, 2001.

附录：完整实验代码（Google Colab 可直接运行）

以下为本项目的完整 Python 代码，可在 Google Colab 中一键运行。代码包含数据生成、预处理、GridSearchCV 超参数调优、随机森林训练、特征重要性分析、混淆矩阵、ROC 曲线、学习曲线、SNR 扫描实验、与 KNN/决策树的对比实验，以及全部图表的生成。

```
# === 完整代码见 colab_code.py ===  
# 运行方法：  
# 1. 打开 https://colab.research.google.com  
# 2. 新建笔记本  
# 3. 将 colab_code.py 全部内容粘贴到代码单元格  
# 4. 点击运行 (Ctrl+Shift+Enter)  
# 5. 从左侧 Files 面板下载 8 张 PNG 图片  
#  
# 代码结构：  
# Section 0: 环境设置  
# Section 1: 高阶累积量理论值表  
# Section 2: 蒙特卡洛数据生成  
# Section 3: 特征分布可视化  
# Section 4: 星座图绘制  
# Section 5: GridSearchCV + 5 折交叉验证  
# Section 6: 分类报告输出  
# Section 7: 混淆矩阵  
# Section 8: 特征重要性  
# Section 9: ROC 曲线  
# Section 10: 学习曲线  
# Section 11: SNR 扫描实验  
# Section 12: KNN/决策树对比  
# Section 13: 汇总输出
```